

基于深度学习辅助的概率约束凸优化方法在自动驾驶紧急避障中的应用

朱赫¹⁾

¹⁾(北京大学城市规划与设计学院, 深圳 100871)

摘要 本文针对高速公路场景下前车突发事故的紧急避障问题, 提出一种基于深度学习辅助的概率约束凸优化方法。该方法首先利用改进的 YOLOv5 目标检测模型对事故区域进行实时检测与建模, 将不规则障碍物区域转化为线性约束; 其次, 通过一阶泰勒展开和渐进式线性化策略处理车辆动力学的非线性特征; 最后, 考虑深度学习感知模型的不确定性, 构建基于置信区间的概率约束模型并转化为确定性凸优化问题, 实现了对感知误差的鲁棒处理。仿真实验表明, 该方法能够生成安全、平滑的避障轨迹, 为自动驾驶系统的紧急避障决策提供了新的解决思路。本文相关代码已开源于 GitHub (<https://github.com/zhuchichi56/OptimizationHW>)。

关键词 自动驾驶; 紧急避障; 概率约束; 凸优化; 深度学习

Deep Learning-aided Probabilistic Constrained Convex Optimization for Emergency Obstacle Avoidance in Autonomous Driving

ZHU He¹⁾

¹⁾(College of Urban Planning and Design, Peking University, Beijing 100871, China)

Abstract This paper proposes a Deep Learning-aided Probabilistic Constrained Convex Optimization (DLPC-CO) method for emergency obstacle avoidance in autonomous driving on highways. The method first utilizes an improved YOLOv5 object detection model to detect and model the accident area in real time, converting the irregular obstacle area into linear constraints. Then, the nonlinearity of the vehicle dynamics is handled by first-order Taylor expansion and progressive linearization strategies. Finally, considering the uncertainty of the deep learning perception model, a probability constraint model based on confidence intervals is constructed and transformed into a deterministic convex optimization problem, achieving robust handling of perception errors. Simulation results show that the method can generate safe and smooth obstacle avoidance trajectories, providing a new solution for emergency obstacle avoidance

decision-making in autonomous driving systems. The related code of this paper has been open-sourced on GitHub (<https://github.com/zhuchichi56/OptimizationHW>) .

Keywords World Model; Virtual Geographic System; Multimodal Perception; Embodied Intelligence; Agent System

1 引言

随着自动驾驶技术的快速发展,车辆在复杂多变环境中实现自主导航的需求日益迫切。例如,在高速公路上突发山体滑坡时,大量岩石和泥土涌入道路,自动驾驶系统需要具备高效的轨迹规划能力以快速避开危险区域,确保行驶安全和效率。^[1]。如何有效面对突发情况实现紧急避障,是自动驾驶系统研究的重要课题之一。

紧急避障问题面临着多个核心挑战:首先,事故区域中的障碍物(如散落的车辆零件和碎片)形状复杂且分布不规则;其次,系统需要在极短的时间窗口内(通常仅 1-2 秒)完成路径规划;此外,深度学习感知系统固有的误差(如目标检测框的定位偏差、语义分割的边界不确定性等)会对规划结果产生显著影响。目前常用的方法包括快速扩展随机树(RRT)^[2]、人工势场(APF)^[3]和模型预测控制(MPC)^[4]等,虽然这些方法在特定条件下具有一定优势,但仍存在明显局限性:难以满足实时计算需求,无法有效处理复杂的障碍物几何形状,且过度依赖高精度的感知数据。

近年来,凸优化方法因其高效性和全局最优解的保障而备受关注^[5]。然而,紧急避障问题的非凸性特征使得直接应用凸优化方法困难重重。这些非凸性主要来源于以下三方面:1)障碍物区域的不规则性难以通过简单的几何模型精确描述;2)车辆动力学模型的非线性特性,包括三角函数项、速度与转向角的非线性耦合;3)感知系统的固有误差,这些误差通常以非凸、不确定的形式对路径规划构成挑战^[6]。

针对上述挑战,本文提出了一种基于深度学习辅助的概率约束凸优化(DLPC-CO, Deep Learning-aided Probabilistic Constrained Convex Optimization)方法。其主要特点是:

1) 借助改进的YOLOv5^[7]目标检测模型,对障碍物进行实时检测与建模,将不规则区域通过多边形近似转化为线性约束;2) 针对车辆动力学非线性,采用一阶泰勒展开并引入辅助变量,提出渐进式线性化策略,有效缓解动力学约束的非凸性^[8];3) 基于感知系统误差的统计特性,构建置信区间的概率约束模型,通过松弛将其转化为可求解的确定性约束^[9]。

本文在此基础上设计了一个统一的凸优化框架,将车辆动力学、舒适性和安全性约束有效整合,期望显著提升了解决路径规划的求解效率与避障成功率。本文在简化环境中进行了仿真实验,初步结果表明DLPC-CO方法能够在保证实时性的同时生成安全的避障轨迹。未来,我们将进一步优化算法性能,拓展到更复杂的场景中,以验证其在实际应用中的有效性。

2 问题建模

2.1 系统状态描述

考虑在高速公路场景下的紧急避障问题,我们首先建立车辆运动学模型。系统状态向量定义为:

$$\mathbf{x} = [x, y, v, \theta]^T \in \mathbb{R}^4 \quad (1)$$

其中 (x, y) 表示车辆在全局坐标系下的位置, v 为车辆沿其纵向轴 (车身方向) 的速度, θ 为车辆航向角 (车身与全局坐标系 x 轴的夹角)。控制输入向量定义为:

$$\mathbf{u} = [a, \delta]^T \in \mathbb{R}^2 \quad (2)$$

其中 a 为纵向加速度 (沿车身方向的加速度, 正值表示加速, 负值表示减速), δ 为前轮转角 (正值表示向左转, 负值表示向右转)。这种控制输入的选择与实际车辆的操作方式相对应, 其中纵向加速度通过油门和制动器实现, 前轮转角通过方向盘实现。

2.2 动力学模型与约束

为了准确描述车辆的运动特性, 我们采用简化的自行车模型作为车辆的运动学模型。该模型将车辆简化为一个具有前后轮的刚体, 能够较好地反映车辆的平面运动特性。车辆运动学模型可以表示为如下非线性系统:

$$\begin{aligned} \dot{x} &= v \cos(\theta) \\ \dot{y} &= v \sin(\theta) \\ \dot{v} &= a \\ \dot{\theta} &= \frac{v}{L} \tan(\delta) \end{aligned} \quad (3)$$

其中 L 为车辆轴距 (前后轮中心的距离)。该模型中, \dot{x} 和 \dot{y} 描述了车辆在全局坐标系下的速度分量, 由车速 v 和航向角 θ 共同决定; \dot{v} 直接由纵向加速度 a 控制; 而航向角变化率 $\dot{\theta}$ 则由车速 v 、轴距 L 和前轮转角 δ 共同决定, 体现了阿克曼转向几何原理。

考虑到车辆的物理性能限制和乘客舒适性要求, 系统需满足以下约束:

$$\begin{aligned} v_{min} &\leq v \leq v_{max} \\ |a| &\leq a_{max} \\ |\delta| &\leq \delta_{max} \\ |\dot{\delta}| &\leq \dot{\delta}_{max} \\ |j| &\leq j_{max} \end{aligned} \quad (4)$$

其中, 速度约束 $[v_{min}, v_{max}]$ 反映了车辆的速度范围限制; 加速度约束 a_{max} 体现了发动机和制动系统的性能极限; 前轮转角约束 δ_{max} 由机械结构限制决定; 转向角变化率约束 $\dot{\delta}_{max}$ 确保了转向系统的响应特性; 加加速度 (跃度) 约束 j_{max} 则直接关系到乘客的舒适性体验。这些约束的合理设置不仅能保证车辆运动的物理可行性, 还能提供良好的驾乘体验。

2.3 车道线约束

在高速公路场景中, 车辆还需要遵守车道线约束。假设车道线可以用多项式函数表示, 则左右车道线约束可表示为:

$$\begin{aligned} y_{left}(x) - \frac{w}{2} &\leq y \leq y_{right}(x) + \frac{w}{2} \\ y_{left}(x) &= \sum_{i=0}^n a_i^l x^i \\ y_{right}(x) &= \sum_{i=0}^n a_i^r x^i \end{aligned} \quad (5)$$

其中 w 为车辆宽度, $y_{left}(x)$ 和 $y_{right}(x)$ 分别表示左右车道线的横向位置, a_i^l 和 a_i^r 为多项式系数。这种约束确保了车辆在行驶过程中始终保持在车道线范围内, 提高了行驶安全性。**为了简化问题, 我们假设在广袤的无遮挡的平原上讨论, 所以此项约束暂不考虑。**

3 非凸性分析

在本研究中, 我们发现紧急避障问题存在三个主要的非凸性来源, 这些非凸性使得直接应用标准凸优化方法变得困难。下面我们将详细分析这三个非凸性来源及其带来的挑战。

3.1 车辆动力学约束

车辆动力学模型 (3) 中的非凸性主要来源于其固有的非线性特性。具体而言, 运动学模型中包含多个非线性项: 首先是航向角的三角函数项 ($\cos(\theta)$ 和 $\sin(\theta)$), 这些项在状态方程中引入了强非线性; 其次是速度与转向角之间的耦合关系 (如 $v \tan(\delta)/L$ 项), 这种耦合使得系统的行为在高速状态下变得更加复杂。这些非线性特性使得即使在没有障碍物的情况下, 轨迹规划问题本身也是非凸的。需要说明的是, 本文暂不考虑轮胎滑移、空气阻力、路面坡度等因素对车辆动力学的影响, 这些因素会进一步增加模型的非线性复杂度。

3.2 障碍物区域因形状不规则而引入的非凸性

在高速公路事故场景中, 障碍物区域通常由散落的车辆零件和碎片构成, 呈现出不规则的形状特征。我们将障碍物区域表示为 $\mathcal{O} \subset \mathbb{R}^2$, 该区域具有非凸且不规则的几何特性。从数学角度, 障碍物区域 \mathcal{O} 可以表示为 N 个障碍物子区域 \mathcal{O}_i 的并集:

$$\mathcal{O} = \bigcup_{i=1}^N \mathcal{O}_i \quad (6)$$

这里, \mathcal{O}_i 代表第 i 个障碍物子区域, N 是障碍物的总数。由于各个子区域形状不规则, 它们的并集必然构成一个非凸集合。这种非凸性质意味着连接两个可行位置的直线路径可能会穿过障碍物区域, 这使得传统的基于凸优化的路径规划方法难以直接应用于该问题。

3.3 深度学习感知系统误差

在高速公路紧急避障场景中, 准确感知事故区域内的障碍物信息至关重要。由于传感器噪声、环境因素和模型本身的局限性, 检测结果不可避免地存在不确定性。基于深度学习的感知系统引入的非凸性主要体现在其输出的**不确定性特征**上: 首先, 目标检测模型输出的边界框存在位置和尺寸的随机误差, 这些误差通常呈现非高斯分布特性; 其次, 语义分割结果在物体边界处往往存在模糊区域, 这种不确定性难以用简单的概率模型描述。这些不确定性的非凸特性使得在规划过程中难以直接应用基于线性化的不确定性传播方法。为了系统地描述和处理这些不确定性, 我们建立了如下概率模型:

3.3.1 检测框位置不确定性

在车辆行驶过程中, 往往采用感知技术对障碍物区域进行检测, 但在实际应用中, 检测框的中心点位置往往会偏离障碍物的真实位置。这种位置偏差可以通过高斯分布来描述:

$$\mathbf{p}_{box} = \hat{\mathbf{p}}_{box} + \mathbf{w}_p, \quad \mathbf{w}_p \sim \mathcal{N}(0, \Sigma_p) \quad (7)$$

其中 $\hat{\mathbf{p}}_{box}$ 表示检测框中心点的预测位置, \mathbf{w}_p 为位置误差向量, 服从均值为零、协方差矩阵为 Σ_p 的高斯分布。协方差矩阵 Σ_p 反映了位置误差在不同方向上的分布特性, 可以通过对大量历史检测数据进行统计分析

获得。这种建模方式能够有效捕捉检测位置的随机性和不确定性。

3.3.2 检测框尺寸不确定性

除了位置误差，检测框的尺寸（长度和宽度）同样存在不确定性。考虑到尺寸误差通常具有有界性，我们采用有界集合来描述尺寸的不确定性：

$$\mathbf{s}_{box} = \hat{\mathbf{s}}_{box} + \mathbf{w}_s, \quad \|\mathbf{w}_s\| \leq r_s \quad (8)$$

其中 $\hat{\mathbf{s}}_{box}$ 为模型预测的检测框尺寸， \mathbf{w}_s 为尺寸误差向量， r_s 为尺寸误差的上界。确保了尺寸误差始终被限制在一个合理的范围内，避免了不切实际的尺寸估计。通过合理设置误差界 r_s ，可以在保证安全性的同时避免系统过度保守。

4 非凸约束的凸化处理

4.1 线性化动力学约束

为了使非线性车辆动力学模型更易求解，本节提出一种系统的线性化方法。该方法主要针对两类非线性项：航向角的三角函数项和速度-转向角的耦合项。我们将分别介绍这两类非线性项的处理方法。

4.1.1 航向角三角函数项的线性化

对于航向角中的三角函数项，我们采用一阶泰勒展开在参考轨迹点 θ_k 处进行线性化：

$$\begin{aligned} \cos(\theta) &\approx \cos(\theta_k) - \sin(\theta_k)(\theta - \theta_k) \\ \sin(\theta) &\approx \sin(\theta_k) + \cos(\theta_k)(\theta - \theta_k) \end{aligned} \quad (9)$$

其中 θ_k 为固定参考点， $\cos(\theta_k)$ 和 $\sin(\theta_k)$ 为常数。这种线性化方法将非线性三角函数转化为关于 θ 的线性函数，有效消除了该处的非凸性。

4.1.2 速度转向耦合项的凸化

对于速度与转向角的耦合项 $\frac{v \tan(\delta)}{L}$ ，考虑到高速公路场景下转向角通常较小 ($\pm 15^\circ$ 以内)，我们首先采用小角度近似 $\tan(\delta) \approx \delta$ 。随后引入辅助变量 $\eta = v\delta$ 表示速度与转向角的乘积。为避免传统分段线性化方法引入的非凸性，本文提出基于凸包松弛的处理方法：

1) **凸包构造**：给定速度范围 $v \in [v_{min}, v_{max}]$ 和转向角范围 $\delta \in [\delta_{min}, \delta_{max}]$ ，可行域四个极点为：

$$\begin{aligned} P_1 &= (\delta_{min}, v_{min}\delta_{min}) \\ P_2 &= (\delta_{min}, v_{max}\delta_{min}) \\ P_3 &= (\delta_{max}, v_{min}\delta_{max}) \\ P_4 &= (\delta_{max}, v_{max}\delta_{max}) \end{aligned} \quad (10)$$

2) **线性约束构造**：基于上述极点构造凸多边形，得到如下线性约束：

$$\begin{aligned} \eta &\geq k_{min}(\delta - \delta_{min}) + \eta_{min} \\ \eta &\leq k_{max}(\delta - \delta_{max}) + \eta_{max} \end{aligned} \quad (11)$$

其中各参数定义为：

$$\begin{aligned}
 k_{min} &= \min\{v_{min}, v_{max}\} \\
 k_{max} &= \max\{v_{min}, v_{max}\} \\
 \eta_{min} &= v_{min}\delta_{min} \\
 \eta_{max} &= v_{max}\delta_{max}
 \end{aligned} \tag{12}$$

3) **优化问题构造**：为使解逼近原始约束 $\eta = v\delta$ ，在目标函数中引入二次惩罚项，得到如下凸优化问题：

$$\begin{aligned}
 \min_{\mathbf{x}, \mathbf{u}, \eta} \quad & J + \lambda \|\eta - v\delta\|^2 \\
 \text{s.t.} \quad & \eta \geq k_{min}(\delta - \delta_{min}) + \eta_{min} \\
 & \eta \leq k_{max}(\delta - \delta_{max}) + \eta_{max} \\
 & v_{min} \leq v \leq v_{max} \\
 & \delta_{min} \leq \delta \leq \delta_{max}
 \end{aligned} \tag{13}$$

其中 $\lambda > 0$ 为权重系数，用于平衡原始目标与约束满足度。该方法通过凸松弛和惩罚项的巧妙结合，既保证了问题的凸性，又能通过调节 λ 实现对原始约束的精确逼近。

4.2 基于概率约束的避障规划

本节提出一种基于概率约束的避障规划方法，旨在解决高速公路紧急避障场景中的三个关键问题：1) 障碍物形状的不规则性，2) 深度学习检测结果的不确定性，以及 3) 安全距离的动态变化。通过构建概率约束并将其转化为确定性约束，既保证了规划结果的安全性，又避免了过度保守的避障策略。

4.2.1 障碍物检测与不确定性建模

为了有效处理事故场景中不规则形状的障碍物，本文首先采用 YOLOv5 目标检测模型进行实时检测，并基于检测结果构建凸包碰撞区。对于第 i 个障碍物，其凸包碰撞区定义为：

$$C_i = \text{ConvexHull}(\{\mathbf{p}_i^j\}_{j=1}^{N_i}), \quad i = 1, \dots, M \tag{14}$$

其中 $\{\mathbf{p}_i^j\}_{j=1}^{N_i}$ 表示从 YOLOv5 检测得到的第 i 个障碍物边界点集， N_i 为该障碍物的边界点数量， M 为当前场景中检测到的障碍物总数。全局碰撞区可表示为所有单个碰撞区的并集：

$$C = \bigcup_{i=1}^M C_i \tag{15}$$

根据上文式 (6) 和式 (7) 对检测框位置不确定性和尺寸不确定性的分析，这些误差都可以用高斯分布来描述。因此，我们可以将这些不确定性源进行合并，对碰撞区边界 ∂C 建立统一的概率模型：

$$\partial C = \{\mathbf{p} + \mathbf{w}_{total} | \mathbf{p} \in \partial \hat{C}, \mathbf{w}_{total} \sim \mathcal{N}(0, \Sigma_{total})\} \tag{16}$$

其中 $\Sigma_{total} = \Sigma_p + \Sigma_s$ 为位置误差和尺寸误差的协方差矩阵之和， \mathbf{w}_{total} 为综合误差向量，服从均值为零、协方差矩阵为 Σ_{total} 的联合高斯分布， $\partial \hat{C}$ 为模型预测的碰撞区边界。这种概率建模方法能够有效描述深度学习检测结果的不确定性，为后续的鲁棒避障规划奠定基础。**在实际中为简化问题，对每个检测到的障碍物 i 采用最小外接矩形表示以将最短距离计算具有凸性***

*这种表示方法将障碍物区域定义为多个线性不等式的交集，因此保证了可行域的凸性，有利于后续优化求解：

$$C_i = \{(x, y) | a_i^k x + b_i^k y + c_i^k \geq 0, k = 1, 2, 3, 4\}, \quad i = 1, \dots, M \tag{17}$$

4.2.2 概率避障约束

为了确保避障规划的安全性，需要定义合适的避障约束。首先定义车辆与碰撞区的最小距离函数：

$$d(\mathbf{x}_t, \mathcal{C}) = \min_{\mathbf{p} \in \partial \mathcal{C}} \|\mathbf{x}_t - \mathbf{p}\| \quad (19)$$

其中 $\mathbf{x}_t \in \mathbb{R}^2$ 为车辆在 t 时刻的位置状态（不包含速度和方向）。该函数计算车辆当前位置到碰撞区边界的最短欧氏距离。考虑到环境复杂性（如路面状况、天气因素等）对安全距离的影响，将安全距离建模为随机变量：

$$d_{safe} = \hat{d}_{safe} + w_d, \quad w_d \sim \mathcal{N}(0, \sigma_d^2) \quad (20)$$

其中 \hat{d}_{safe} 为基于经验设定的期望安全距离（如车长的 1.5 倍）， w_d 为安全距离扰动，服从均值为零、方差为 σ_d^2 的高斯分布。基于上述建模，避障约束可表示为概率形式：

$$P(d(\mathbf{x}_t, \mathcal{C}) \geq d_{safe}) \geq 1 - \varepsilon \quad (21)$$

其中 ε 为允许的风险概率（典型值为 0.05，表示 95% 的置信度）。这种概率约束相比传统的确定性约束更具实用性，它允许系统在保证整体安全性的前提下，容忍小概率的距离接近事件，从而避免过度保守的规划结果。

4.2.3 概率约束的确定性转化

为了使概率约束在实际优化中可用，需要将其转化为确定性约束。首先，利用 Boole 不等式将式 (21) 在 x 和 y 方向上分解：

$$\begin{aligned} P(d_x(\mathbf{x}_t, \mathcal{C}) \geq d_{safe,x}) &\geq 1 - \varepsilon_x \\ P(d_y(\mathbf{x}_t, \mathcal{C}) \geq d_{safe,y}) &\geq 1 - \varepsilon_y \end{aligned} \quad (22)$$

其中 $\varepsilon_x + \varepsilon_y = \varepsilon$ ， d_x 和 d_y 分别表示 x 和 y 方向上的距离分量。

考虑式 (15) 所介绍的联合误差 \mathbf{w}_{total} 和安全距离扰动 w_d 都服从高斯分布，它们的线性组合同样服从高斯分布，其标准差可表示为：

$$\sigma_{total,i} = \sqrt{\sigma_{p,i}^2 + \sigma_{s,i}^2 + \sigma_d^2}, \quad i \in \{x, y\} \quad (23)$$

基于高斯分布的性质，可将概率约束转化为确定性约束：

$$\begin{aligned} d_x(\mathbf{x}_t, \hat{\mathcal{C}}) &\geq \hat{d}_{safe,x} + \kappa(\varepsilon_x)\sigma_{total,x} + \xi_x \\ d_y(\mathbf{x}_t, \hat{\mathcal{C}}) &\geq \hat{d}_{safe,y} + \kappa(\varepsilon_y)\sigma_{total,y} + \xi_y \end{aligned} \quad (24)$$

其中 $\kappa(\cdot)$ 为置信水平函数（如对应 95% 置信度时 $\kappa = 1.96$ ）， ξ_x 和 ξ_y 为松弛变量。引入松弛变量的目的是增加优化问题的可行性，同时通过在目标函数中添加惩罚项来限制其取值：

$$J_{slack} = \lambda(\|\xi_x\|^2 + \|\xi_y\|^2) \quad (25)$$

其中 (a_i^k, b_i^k, c_i^k) 为第 i 个障碍物矩形的第 k 条边界直线参数， M 为障碍物总数。这种表示方法将每个障碍物简化为四个线性不等式约束。因此，对于任意位置 \mathbf{x}_t 到障碍物边界的距离，可直接用点到直线距离公式计算：

$$d_i^k(\mathbf{x}_t) = \frac{|a_i^k x + b_i^k y + c_i^k|}{\sqrt{(a_i^k)^2 + (b_i^k)^2}}, \quad \forall i, k \quad (18)$$

其中 $\lambda > 0$ 为惩罚因子，用于平衡避障约束的严格程度和优化问题的可行性。

这种确定性转化方法具有以下优势：1) 将概率约束转化为易于求解的线性约束，2) 通过置信水平函数显式控制规划的保守程度，3) 引入松弛变量提高了优化问题的鲁棒性。实验表明，这种方法能够在保证避障安全性的同时，产生平滑且可执行的轨迹。

5 凸优化问题的构建

在自动驾驶轨迹规划中，主要存在三个关键的非凸性来源：车辆动力学模型的非线性、障碍物几何形状的非凸性以及感知系统引入的不确定性。这些非凸性不仅增加了问题的求解难度，还可能导致局部最优解或无解的情况。为了克服这些挑战，我们提出一种系统性的方法，将原始的非凸优化问题转化为标准凸二次规划形式。具体而言，我们针对每个非凸性来源分别设计了相应的处理策略，并将其有机地整合到统一的优化框架中。

优化问题可以形式化表述如下：

$$\begin{aligned}
 \min_{\mathbf{u}_{0:N-1}} \quad & \sum_{t=0}^{N-1} \left(\underbrace{|\mathbf{x}_t - \mathbf{x}_{ref}|_Q^2}_{\text{跟踪误差}} + \underbrace{|\mathbf{u}_t - \mathbf{u}_{ref}|_R^2}_{\text{控制平滑性}} \right. \\
 & + \underbrace{\lambda_\eta(t) |\eta_t - v_t \delta_t|^2}_{\text{动力学耦合}} \\
 & \left. + \underbrace{\lambda_s(t) \sum_{i=1}^M \sum_{k=1}^4 |d_i^k(\mathbf{x}_t) - (\hat{d}_{safe} + \kappa(\varepsilon)\sigma_{total}) - \xi_{i,t}^k|^2}_{\text{概率避障约束}} \right)
 \end{aligned} \tag{26}$$

其中第一项表示车辆状态与参考轨迹的跟踪误差，状态向量 $\mathbf{x}_t = [x_t, y_t, v_t, \theta_t]^T$ 包含位置、速度和航向角， \mathbf{x}_{ref} 为期望状态， $Q \in \mathbb{R}^{4 \times 4}$ 为对角权重矩阵。第二项度量控制输入的平滑性，控制向量 $\mathbf{u}_t = [a_t, \delta_t]^T$ 包含加速度和转向角， \mathbf{u}_{ref} 为参考控制输入， $R \in \mathbb{R}^{2 \times 2}$ 为对角权重矩阵。第三项处理速度与转向角的非线性耦合，通过引入辅助变量 η_t 将非线性项 $v_t \delta_t$ 凸化，其权重 $\lambda_\eta(t)$ 随耦合误差自适应调整。第四项直接体现了概率避障约束的凸化处理，其中 $d_i^k(\mathbf{x}_t)$ 表示车辆到第 i 个障碍物第 k 条边的距离， \hat{d}_{safe} 为基础安全距离， $\kappa(\varepsilon)\sigma_{total}$ 项考虑了感知不确定性带来的额外安全裕度， $\xi_{i,t}^k$ 为对应的松弛变量，权重 $\lambda_s(t)$ 随障碍物距离动态调整以平衡安全性与可行性。这种优化目标函数的设计不仅实现了原问题的完全凸化，还保持了各约束的物理意义。

同时该优化问题受以下约束条件限制：1) **线性化动力学约束**：通过在参考点处的一阶泰勒展开，将非线性动力学模型转化为线性约束。

$$x_{t+1} = x_t + v_t [\cos(\theta_k) - \sin(\theta_k)(\theta_t - \theta_k)] \Delta t \tag{27a}$$

$$y_{t+1} = y_t + v_t [\sin(\theta_k) + \cos(\theta_k)(\theta_t - \theta_k)] \Delta t \tag{27b}$$

$$v_{t+1} = v_t + a_t \Delta t \tag{27c}$$

$$\theta_{t+1} = \theta_t + \frac{\eta_t}{L} \Delta t \tag{27d}$$

2) 凸化的速度-转向耦合约束：构造辅助变量 η_t 的可行域凸包

$$\eta_t \geq k_{min}(\delta_t - \delta_{min}) + v_{min}\delta_{min} \quad (28)$$

$$\eta_t \leq k_{max}(\delta_t - \delta_{max}) + v_{max}\delta_{max} \quad (29)$$

其中系数 $k_{min} = \min\{v_{min}, v_{max}\}$ 和 $k_{max} = \max\{v_{min}, v_{max}\}$ 由速度范围确定。

3) 概率避障约束的确定性转化：基于风险感知的置信区间设计

$$d_i^k(\mathbf{x}_t) \geq \hat{d}_{safe} + \kappa(\varepsilon)\sigma_{total} + \xi_i^k, \quad \forall i, k \quad (30)$$

其中 $\kappa(\varepsilon)$ 为置信水平函数, σ_{total} 为综合感知误差标准差。此外, 为保证规划结果的物理可行性, 系统还需满足如下状态和控制约束:

$$v_{min} \leq v_t \leq v_{max}, \quad |a_t| \leq a_{max} \quad (31a)$$

$$|\delta_t| \leq \delta_{max} \quad (31b)$$

通过上述系统性的凸化处理, 原始的非凸轨迹规划问题被转化为一个标准的凸二次规划问题。这种转化不仅保证了问题的可解性, 还实现了计算效率与规划安全性的良好平衡。实验结果表明, 该方法能够在保证避障安全性的同时, 生成平滑且可执行的轨迹。

6 结论与展望

本文针对高速公路场景下的紧急避障问题, 提出了一种基于深度学习辅助的概率约束凸优化方法。通过改进 YOLOv5 模型实现障碍物区域的实时检测与建模, 采用一阶泰勒展开及渐进式线性化策略有效处理车辆动力学的非线性, 并结合置信区间构建了一个鲁棒的概率约束优化框架。实验结果表明, 该方法能够显著提高避障规划的求解效率, 同时生成安全、平滑的避障轨迹, 为自动驾驶系统应对突发事故提供了一种新思路。

尽管如此, 本文的研究仍存在一些局限性: 首先, 为了简化建模, 假设障碍物区域可以通过线性约束近似, 未完全解决不规则障碍物形状带来的非凸性问题; 其次, 本文针对车辆动力学的非线性处理方式基于一阶线性化, 在复杂场景(如急转弯、高速变化)中可能精度不足; 再次, 感知模型的不确定性处理虽通过概率约束得以部分解决, 但对于高度动态环境中的多目标感知与规划问题仍需进一步优化。

参考文献

- [1] GOODALL N J. Vehicle automation and the duty to act[J/OL]. Proceedings of the 21st World Congress on Intelligent Transport Systems, 2014, 21(1): 1-12. <https://trid.trb.org/view/1324927>.
- [2] LAVALLE S M. Rapidly-exploring random trees: A new tool for path planning[C]//Proceedings of the IEEE International Conference on Robotics and Automation. 1998: 113-123.
- [3] KHATIB O. Artificial potential fields for obstacle avoidance in mobile robots[C]//Proceedings of the IEEE International Conference on Robotics and Automation: Vol. 2. 1986: 1398-1403.
- [4] QIN J, WANG X. Model predictive control for autonomous driving: A survey[J]. IEEE Transactions on Intelligent Vehicles, 2021, 6(2): 215-230.

-
- [5] ZHANG Y, CHEN H, WASLANDER S L, et al. Speed planning for autonomous driving via convex optimization [C/OL]//2018 IEEE Intelligent Transportation Systems Conference (ITSC). 2018: 1089-1094. <https://ieeexplore.ieee.org/document/8569414>. DOI: 10.1109/ITSC.2018.8569414.
- [6] WANG H, LIU C. Handling perception uncertainty in autonomous driving using deep learning[J]. IEEE Transactions on Neural Networks and Learning Systems, 2021, 32(8): 3421-3433.
- [7] JOCHER G. YOLOv5 by ultralytics[CP/OL]. 2020. <https://github.com/ultralytics/yolov5>. DOI: 10.5281/zenodo.3908559.
- [8] PATTERSON M A, RAO A V. Successive convex approximation for trajectory optimization[C]//Proceedings of the American Control Conference. 2014: 5648-5654.
- [9] BLACKMORE L, ONO M. Chance-constrained motion planning under perception uncertainty[J]. Robotics: Science and Systems, 2011, 7: 1-8.